

Mapeamento 3D de Ambientes sem GPS com Drone: Integração de Fluxo Óptico, IMU e LiDAR

TRABALHO DE CONCLUSÃO DE CURSO

por

Gabriel Holsback Dantas - holsback@sempreceub.com - RA: 22310899
Rafael De Queiroz Lavoyer - rafael.lavoyer@sempreceub.com - RA: 22208760

Resumo: Este trabalho apresenta uma metodologia de aquisição e processamento para localização relativa e geração de nuvem de pontos em ambientes sem sinal de GPS. A abordagem combina sensor óptico de fluxo, sensor de distância ToF, duas unidades de medição inercial e LiDAR 2D. O fluxo óptico fornece a odometria primária no plano horizontal, a IMU estima atitude e preenche intervalos sem medição óptica, e o LiDAR é transformado do referencial local do drone para o referencial global para reconstrução tridimensional do ambiente.

Orientador: Hudson Capanema Zaidan
Turma: UN2026/07
Curso: Engenharia da Computação
Campus: Asa Norte
Turno: Noturno

Sumário

Dedicatória	5
Resumo	6
Abstract	7
Abreviaturas	8
Lista de Símbolos	9
1 Introdução	10
1.1 Problema de pesquisa	10
1.2 Objetivos	10
1.3 Contribuições	11
1.4 Organização do trabalho	11
2 Fundamentação Teórica	12
2.1 Navegação em ambientes sem GPS	12
2.2 Sensores utilizados	12
2.2.1 Unidade de Medição Inercial	12
2.2.2 Sensor óptico de fluxo e ToF	12
2.2.3 LiDAR	13
2.3 Atitude e transformação de referenciais	13
2.4 Filtro de Madgwick	13
2.5 Aceleração linear e integração discreta	14
2.6 Combinação entre fluxo óptico e IMU	14
2.7 Processamento da nuvem de pontos	14
2.8 Filtragem estatística e física	14
3 Metodologia	16
3.1 Visão geral	16
3.2 Plataforma de aquisição	16
3.3 Dados coletados	17
3.4 Pré-processamento da IMU	17
3.4.1 Calibração e filtragem	18
3.4.2 Média das duas IMUs	18
3.5 Estimativa de atitude	18
3.6 Aceleração linear no mundo	18
3.7 Estimativa de posição por fluxo óptico e IMU	19
3.7.1 Fluxo óptico como fonte primária	19
3.7.2 Eventos de fluxo óptico e intervalos sem medição	19
3.7.3 Associação da pose às medições LiDAR	19
3.8 Processamento da nuvem LiDAR global	19
3.8.1 Filtros aplicados à nuvem	19
3.8.2 Correção da rotação do LiDAR principal	20
3.8.3 Transformação para o referencial global	20
3.8.4 Análise de erro geométrico horizontal	20
3.9 Produtos do processamento	20

4	Implementação, Resultados e Conclusão	21
4.1	Implementação realizada	21
4.2	Resultados obtidos	22
4.3	Limitações	24
4.4	Conclusão	25
4.5	Trabalhos futuros	25

Dedicatória

Resumo

Ambientes internos, cavernas e áreas confinadas impõem uma limitação direta ao uso de GPS para navegação e mapeamento. Este trabalho apresenta uma metodologia para estimar a localização relativa de um drone e gerar uma nuvem de pontos tridimensional a partir da integração de fluxo óptico, sensores inerciais e LiDAR. A posição no plano horizontal é estimada prioritariamente pelo sensor óptico de fluxo, corrigido por uma medida ToF de altura usada como escala. A IMU, composta por acelerômetros e giroscópios, é utilizada para estimar atitude por meio de quaternions e para preencher intervalos nos quais o sensor óptico não registra deslocamento. Essa estratégia evita depender da dupla integração livre da aceleração por longos períodos, processo conhecido por acumular erro devido a ruído, viés e deriva.

O processamento implementado converte as medições inerciais para unidades do Sistema Internacional, aplica calibração de viés no giroscópio, filtragem passa-baixa Butterworth, média entre duas IMUs e estimação de orientação pelo filtro de Madgwick. Em seguida, os deslocamentos ópticos são acumulados em coordenadas globais no plano XY , enquanto a aceleração transformada para o referencial global é usada apenas como apoio nos intervalos sem eventos de fluxo óptico. Para o mapeamento, cada ponto do LiDAR é filtrado por critérios físicos e estatísticos, convertido para coordenadas locais no plano de varredura $X-Z$, corrigido pela rotação do LiDAR em torno do eixo Y do drone e transformado para o referencial global usando a atitude e a posição estimadas. Os resultados demonstram um fluxo reprodutível de aquisição, filtragem, estimação de pose e geração de nuvem de pontos global, com limitações explicitadas quanto à ausência de estimativa vertical dedicada e à necessidade de calibração extrínseca final dos sensores.

Palavras-chave: drone; ambiente sem GPS; fluxo óptico; IMU; LiDAR; nuvem de pontos; fusão sensorial.

Abstract

Indoor, cave-like and confined environments restrict the use of GPS for navigation and mapping. This work presents a methodology for estimating the relative position of a drone and generating a three-dimensional point cloud by integrating optical flow, inertial sensors and LiDAR. Horizontal position is primarily estimated from an optical flow sensor, scaled by a ToF height measurement. The IMU, composed of accelerometers and gyroscopes, is used to estimate attitude through quaternions and to propagate motion during intervals in which the optical sensor does not report displacement. This approach avoids relying on unconstrained double integration of acceleration for long periods, which is known to accumulate error due to noise, bias and drift.

The implemented processing flow converts inertial measurements to SI units, estimates gyroscope bias, applies a low-pass Butterworth filter, averages two IMUs and estimates orientation with the Madgwick filter. Optical flow increments are then accumulated in the global XY plane, while acceleration transformed to the global frame is used only as support during optical-flow gaps. For mapping, each LiDAR point is filtered using physical and statistical criteria, converted to local coordinates in the $X-Z$ scanning plane, corrected for the LiDAR rotation around the drone Y axis and transformed into the global frame using the estimated attitude and position. The results show a reproducible acquisition, filtering, pose-estimation and global point-cloud generation workflow, while making explicit the current limitations regarding vertical position estimation and final extrinsic sensor calibration.

Keywords: drone; GPS-denied environment; optical flow; IMU; LiDAR; point cloud; sensor fusion.

Abreviaturas

GPS	Sistema de Posicionamento Global (<i>Global Positioning System</i>)
IMU	Unidade de Medição Inercial (<i>Inertial Measurement Unit</i>)
LiDAR	Detecção e medição por luz (<i>Light Detection and Ranging</i>)
ToF	Tempo de voo (<i>Time of Flight</i>)
MEMS	Sistemas microeletromecânicos (<i>Micro-Electro-Mechanical Systems</i>)
RPY	<i>Roll, pitch e yaw</i>
DoF	Graus de liberdade (<i>Degrees of Freedom</i>)
CSV	Valores separados por vírgula (<i>Comma-Separated Values</i>)
SD	Cartão de memória digital (<i>Secure Digital</i>)
UART	Receptor/transmissor assíncrono universal (<i>Universal Asynchronous Receiver/Transmitter</i>)
I2C	Barramento serial inter-integrado (<i>Inter-Integrated Circuit</i>)
SPI	Interface serial periférica (<i>Serial Peripheral Interface</i>)
PWM	Modulação por largura de pulso (<i>Pulse Width Modulation</i>)
MCU	Microcontrolador (<i>Microcontroller Unit</i>)
ZYX	Sequência de rotações usada na composição $R_z(\psi)R_y(\theta)R_x(\phi)$
W	Referencial do mundo ou global (<i>World Frame</i>)
B	Referencial do corpo do drone (<i>Body Frame</i>)
L	Referencial local do LiDAR (<i>LiDAR Frame</i>)

Lista de Símbolos

t	Tempo da amostra, em segundos
t_{us}	Timestamp registrado pelo microcontrolador, em microssegundos
Δt_i	Intervalo entre as amostras $i - 1$ e i
f_s	Frequência de amostragem estimada a partir de Δt
$\mathbf{p}$	Posição ou coordenada de um ponto
$\mathbf{p}_{drone,G}$	Posição do drone no referencial global
$\mathbf{v}$	Velocidade do drone no referencial global
$\mathbf{a}$	Aceleração linear
$\tilde{\mathbf{a}}_B$	Aceleração específica medida pela IMU no referencial do corpo
$\mathbf{a}_G$	Aceleração linear no referencial global após compensação da gravidade
$\mathbf{g}_G$	Vetor gravidade no referencial global
g	Módulo da aceleração da gravidade, adotado como $9,81 \text{ m/s}^2$
$\boldsymbol{\omega}$	Velocidade angular medida pelo giroscópio
$\mathbf{b}_a, \mathbf{b}_\omega$	Viés do acelerômetro e do giroscópio
$\boldsymbol{\eta}_a, \boldsymbol{\eta}_\omega$	Ruído de medição do acelerômetro e do giroscópio
d	Deriva acumulada pela integração temporal dos erros dos sensores
ϕ	Ângulo de <i>roll</i> , rotação em torno do eixo X
θ	Ângulo de <i>pitch</i> , rotação em torno do eixo Y
ψ	Ângulo de <i>yaw</i> , rotação em torno do eixo Z
$\mathbf{q}$	Quaternion de atitude no formato $[q_w, q_x, q_y, q_z]$
β	Ganho do filtro de Madgwick
$\mathbf{R}_B^G$	Matriz de rotação que transforma vetores do corpo do drone para o referencial global
R_x, R_y, R_z	Matrizes elementares de rotação em torno dos eixos X , Y e Z
$\Delta x_f, \Delta y_f$	Deslocamentos incrementais do sensor óptico de fluxo, em centímetros no CSV
h	Altura medida pelo ToF
h_0	Altura nominal usada na escala do fluxo óptico
k_h	Fator de escala do ToF, dado por h/h_0
$\mathbf{p}_{flow}$	Posição acumulada a partir do fluxo óptico no plano XY
$\mathbf{p}_{fused}$	Posição final após combinação de fluxo óptico com propagação inercial nos intervalos sem eventos
α_L	Ângulo de varredura do LiDAR, em centésimos de grau no CSV bruto
θ_L	Ângulo de varredura do LiDAR convertido para radianos
r_L	Distância medida pelo LiDAR
I_L	Intensidade do retorno LiDAR
γ_Y	Ângulo físico de varredura/rotação do LiDAR principal em torno do eixo Y do drone
$\mathbf{p}_L$	Coordenada do ponto no referencial local do LiDAR
$\mathbf{p}_B$	Coordenada do ponto no referencial do corpo do drone
$\mathbf{p}_G$	Coordenada global do ponto da nuvem
$\mathbf{R}_B^L$	Rotação extrínseca entre LiDAR e corpo do drone
$\mathbf{t}_B^L$	Translação extrínseca entre LiDAR e corpo do drone
Q_1, Q_3	Primeiro e terceiro quartis usados na cerca de Tukey
IQR	Intervalo interquartil, $IQR = Q_3 - Q_1$
τ_I, τ_r	Limiares automáticos de intensidade e distância calculados por Otsu

1

Introdução

O mapeamento tridimensional de ambientes confinados é relevante para inspeção, documentação e exploração de locais onde a presença humana pode ser arriscada ou operacionalmente custosa. Cavernas, galerias, áreas industriais internas e regiões de difícil acesso têm em comum a baixa disponibilidade de infraestrutura externa de posicionamento. Em particular, sistemas baseados em GPS tendem a apresentar indisponibilidade ou degradação severa nesses cenários, exigindo métodos de localização relativa baseados em sensores embarcados [16, 1].

Uma solução direta seria integrar as acelerações medidas por uma Unidade de Medição Inercial (IMU) para obter velocidade e posição. Entretanto, essa abordagem isolada é limitada: pequenos vieses, ruídos de quantização e erros de atitude são integrados ao longo do tempo, produzindo deriva crescente na estimativa de posição [17, 4, 3]. Por outro lado, sensores ópticos de fluxo medem deslocamentos relativos da superfície observada entre quadros consecutivos, fornecendo uma fonte direta de odometria no plano observado, especialmente útil em navegação indoor e em ambientes sem GPS [5, 9].

Este trabalho adota uma arquitetura híbrida. O sensor óptico de fluxo é tratado como fonte primária de deslocamento no plano horizontal, com correção de escala pela altura medida por um sensor ToF. A IMU complementa essa estimativa ao fornecer atitude do drone e ao preencher pequenos intervalos nos quais o sensor óptico não registra evento de movimento. O LiDAR 2D, por sua vez, fornece distância, ângulo e intensidade de retorno para cada ponto de varredura. Com a posição e a atitude estimadas, cada ponto LiDAR é transformado do referencial local do sensor para o referencial global, resultando em uma nuvem de pontos tridimensional.

1.1 Problema de pesquisa

O problema investigado pode ser resumido na seguinte pergunta: como estimar a posição relativa de uma plataforma móvel em ambiente sem GPS e usar essa pose para transformar medições LiDAR em uma nuvem de pontos global coerente? A resposta proposta combina três fontes de informação com papéis distintos: fluxo óptico para deslocamento horizontal, IMU para orientação e propagação em intervalos sem medição óptica, e LiDAR para geometria do ambiente.

1.2 Objetivos

O objetivo geral deste trabalho é desenvolver e documentar um fluxo de aquisição e processamento capaz de estimar a localização relativa de um drone em ambiente sem GPS e gerar uma nuvem de pontos tridimensional no referencial global a partir da combinação de sensor óptico, IMU e LiDAR.

Os objetivos específicos são:

- Integrar em uma plataforma embarcada sensores de fluxo óptico, ToF, IMU e LiDAR, registrando os dados em formato sincronizado por timestamp.
- Converter e filtrar os sinais inerciais para estimar atitude e aceleração linear no referencial global.

- Estimar a trajetória no plano XY usando fluxo óptico como fonte primária e integração inercial apenas nos intervalos sem eventos do sensor óptico.
- Processar os pontos LiDAR com filtros físicos e estatísticos, convertendo distância e ângulo para coordenadas locais.
- Transformar a nuvem local do LiDAR para o referencial global usando posição, atitude e hipóteses de montagem do sensor.
- Identificar limitações experimentais e parâmetros que ainda dependem de calibração final.

1.3 Contribuições

As principais contribuições deste trabalho são:

- Definição de uma arquitetura de sensoriamento para navegação relativa em ambiente sem GPS, usando fluxo óptico como odometria primária e IMU como apoio inercial.
- Definição de um fluxo de processamento para conversão de unidades, calibração de viés do giroscópio, filtragem Butterworth, estimação de atitude por Madgwick e fusão de posição no plano XY .
- Definição de um fluxo de geração de nuvem global que considera a rotação do LiDAR principal em torno do eixo Y do drone e aplica filtros automáticos de intensidade, distância e continuidade de pose.
- Organização das hipóteses e limitações do experimento, especialmente a ausência de odometria vertical dedicada e a necessidade de validação da calibração extrínseca entre sensores.

1.4 Organização do trabalho

O Capítulo 2 apresenta os conceitos de sensores embarcados, navegação inercial, fluxo óptico, atitude, transformações de coordenadas e filtragem usados no projeto. O Capítulo 3 descreve a plataforma, os dados coletados e o método de processamento adotado. O Capítulo 4 apresenta a implementação, os resultados obtidos, as limitações e os trabalhos futuros.

2

Fundamentação Teórica

2.1 Navegação em ambientes sem GPS

Em ambientes internos ou subterrâneos, a localização de uma plataforma móvel precisa ser estimada a partir de sensores embarcados. Esse problema é uma forma de navegação relativa: a origem do referencial global é definida no início da coleta e a trajetória subsequente é expressa em relação a essa origem. Em robótica móvel, tal estimativa costuma combinar modelos de movimento, medições de sensores e tratamento explícito de incertezas [16].

No caso de drones multirrotores, a atitude do corpo rígido influencia tanto o movimento quanto a interpretação dos sensores. Os ângulos de *roll*, *pitch* e *yaw* descrevem a rotação do corpo em relação ao mundo, enquanto a posição e a velocidade descrevem a translação do centro de referência da plataforma [1].

2.2 Sensores utilizados

2.2.1 Unidade de Medição Inercial

Uma IMU mede aceleração específica e velocidade angular em seu próprio referencial. No projeto, as leituras brutas dos acelerômetros e giroscópios são armazenadas como inteiros e convertidas para unidades do Sistema Internacional usando as escalas do sensor configurado:

$$\mathbf{a}_{SI} = \mathbf{c}_a \frac{g}{16384}, \quad \boldsymbol{\omega}_{SI} = \mathbf{c}_\omega \frac{\pi}{180 \cdot 131}, \quad (2.1)$$

em que $\mathbf{c}_a$ e $\mathbf{c}_\omega$ são as contagens brutas de acelerômetro e giroscópio. Essas constantes correspondem às faixas $\pm 2g$ e $\pm 250^\circ/s$, compatíveis com os registradores da família MPU usada no sistema de aquisição [14, 15].

A medição inercial contém viés e ruído. De forma simplificada:

$$\tilde{\mathbf{a}}_B = (\mathbf{R}_B^G)^T \left(\mathbf{a}_G + \begin{bmatrix} 0 \\ 0 \\ g \end{bmatrix} \right) + \mathbf{b}_a + \boldsymbol{\eta}_a, \quad \tilde{\boldsymbol{\omega}}_B = \boldsymbol{\omega}_B + \mathbf{b}_\omega + \boldsymbol{\eta}_\omega. \quad (2.2)$$

Assim, quando a aceleração é integrada para estimar velocidade e posição, erros pequenos deixam de ser apenas ruído instantâneo e passam a se acumular. Um viés constante de aceleração, por exemplo, produz erro de posição proporcional a t^2 . Essa é a principal razão para não usar a IMU como fonte primária de posição por longos intervalos [17, 4, 3].

2.2.2 Sensor óptico de fluxo e ToF

Sensores de fluxo óptico estimam o deslocamento aparente entre imagens consecutivas da superfície observada. O princípio é próximo aos métodos clássicos de registro de imagens, como Lucas-Kanade, mas no sensor PMW3901 parte do processamento é realizada internamente pelo próprio circuito, que disponibiliza deslocamentos incrementais em X e Y por SPI [5, 9]. No sistema de aquisição, esses incrementos são registrados em centímetros.

Como a conversão entre deslocamento em pixels e deslocamento métrico depende da altura em relação à superfície, o sensor ToF VL53L1X é usado para corrigir a escala do fluxo óptico [13]. A correção de escala adotada é:

$$k_h = \frac{h}{h_0}, \quad \Delta \mathbf{p}_{flow,i} = \frac{k_h}{100} \begin{bmatrix} \Delta x_{f,i} \\ \Delta y_{f,i} \\ 0 \end{bmatrix}, \quad (2.3)$$

em que h é a altura ToF válida, h_0 é a altura nominal usada na escala do sensor óptico e o fator 100 converte centímetros para metros. Leituras ToF entre 20 e 300 mm são consideradas fisicamente válidas para a configuração experimental; fora desse intervalo, substitui-se h por $h_0 = 90$ mm para evitar escalas incoerentes com o alcance operacional do sensor.

2.2.3 LiDAR

O LiDAR LD06 mede distância por tempo de voo e fornece pacotes seriais contendo ângulos, distâncias e intensidade de retorno. O sensor opera com varredura de 360°, comunicação UART a 230400 baud e distâncias em milímetros conforme a documentação do fabricante [11]. A intensidade I_L é usada como indicador de qualidade do retorno, pois retornos fracos tendem a estar associados a leituras mais ruidosas ou inválidas.

2.3 Atitude e transformação de referenciais

A orientação do drone pode ser representada por ângulos de Euler ou por quaternions. Neste trabalho, a atitude é estimada por quaternions e posteriormente expressa por *roll*, *pitch* e *yaw* para compor as matrizes de rotação. Para a transformação final dos pontos, usa-se a convenção ZYX:

$$\mathbf{R}_B^G = R_z(\psi)R_y(\theta)R_x(\phi), \quad (2.4)$$

com:

$$R_x(\phi) = \begin{bmatrix} 1 & 0 & 0 \\ 0 & \cos \phi & -\sin \phi \\ 0 & \sin \phi & \cos \phi \end{bmatrix}, \quad R_y(\theta) = \begin{bmatrix} \cos \theta & 0 & \sin \theta \\ 0 & 1 & 0 \\ -\sin \theta & 0 & \cos \theta \end{bmatrix}, \quad R_z(\psi) = \begin{bmatrix} \cos \psi & -\sin \psi & 0 \\ \sin \psi & \cos \psi & 0 \\ 0 & 0 & 1 \end{bmatrix}. \quad (2.5)$$

Ângulos de Euler são intuitivos, mas dependem da ordem de rotação e podem apresentar singularidades. Por isso, a estimação interna de atitude por quaternion é mais adequada para propagação temporal, enquanto os ângulos são mantidos como forma legível de exportação [2, 12].

2.4 Filtro de Madgwick

O filtro de Madgwick estima a orientação combinando a integração do giroscópio com uma correção baseada na direção da gravidade observada pelo acelerômetro [6]. A forma discreta adotada deriva da seguinte equação diferencial:

$$\dot{\mathbf{q}} = \frac{1}{2} \mathbf{q} \otimes \begin{bmatrix} 0 \\ \boldsymbol{\omega} \end{bmatrix} - \beta \frac{\mathbf{J}^T \mathbf{f}}{\|\mathbf{J}^T \mathbf{f}\|}, \quad (2.6)$$

em que $\mathbf{q}$ é o quaternion de atitude, $\boldsymbol{\omega}$ é a velocidade angular corrigida de viés, $\mathbf{f}$ é o erro entre a direção da gravidade estimada e a medida pelo acelerômetro, $\mathbf{J}$ é a Jacobiana desse erro e β controla o peso da correção. O ganho β é estimado a partir do desvio padrão do giroscópio na janela inicial de calibração:

$$\beta = \sqrt{\frac{3}{4}} \sigma_{\omega}. \quad (2.7)$$

2.5 Aceleração linear e integração discreta

Após estimar a atitude, a aceleração medida no corpo é rotacionada para o referencial global e a gravidade é removida:

$$\mathbf{a}_G = \mathbf{R}_B^G \tilde{\mathbf{a}}_B - \begin{bmatrix} 0 \\ 0 \\ g \end{bmatrix}. \quad (2.8)$$

Quando a IMU é usada nos intervalos sem eventos de fluxo óptico, velocidade e deslocamento são calculados pela regra do trapézio:

$$\mathbf{v}_i = \mathbf{v}_{i-1} + \frac{\mathbf{a}_{i-1} + \mathbf{a}_i}{2} \Delta t_i, \quad \mathbf{p}_i = \mathbf{p}_{i-1} + \frac{\mathbf{v}_{i-1} + \mathbf{v}_i}{2} \Delta t_i. \quad (2.9)$$

A integração não é executada livremente por toda a trajetória. Ela é restrita aos intervalos em que o fluxo óptico não reporta deslocamento, reduzindo a exposição ao acúmulo de deriva. Esse uso é compatível com a noção de propagação inercial assistida por medições externas [3].

2.6 Combinação entre fluxo óptico e IMU

A trajetória final no plano XY é ancorada pelos eventos do sensor óptico. Se dois eventos de fluxo óptico ocorrem nos tempos t_a e t_b , a IMU fornece apenas a forma relativa do deslocamento dentro do intervalo. Esse deslocamento é escalado para coincidir com os pontos ópticos nas extremidades:

$$\mathbf{p}_{fused}(\tau) = \mathbf{p}_{flow}(t_a) + \Delta \mathbf{s}_{IMU}(\tau) \odot \frac{\mathbf{p}_{flow}(t_b) - \mathbf{p}_{flow}(t_a)}{\Delta \mathbf{s}_{IMU}(t_b)}, \quad t_a \leq \tau \leq t_b, \quad (2.10)$$

em que $\odot$ indica operação componente a componente. Quando o deslocamento inercial do intervalo é numericamente nulo, usa-se interpolação linear entre os dois pontos ópticos.

2.7 Processamento da nuvem de pontos

O LiDAR principal é modelado como um sensor 2D cujo plano de varredura, pela montagem física adotada, é o plano local $X-Z$ do drone. O eixo Y é o eixo de rotação do LiDAR. Assim, cada medição válida é convertida para:

$$\theta_L = \frac{\pi}{180} 0,01 \alpha_L, \quad \mathbf{p}_L = \begin{bmatrix} r_L \sin \theta_L \\ 0 \\ r_L \cos \theta_L \end{bmatrix}. \quad (2.11)$$

A transformação para o referencial global combina a calibração extrínseca LiDAR–corpo, a atitude do drone e a posição estimada:

$$\mathbf{p}_G = \mathbf{R}_B^G (\mathbf{R}_B^L \mathbf{p}_L + \mathbf{t}_B^L) + \mathbf{p}_{drone,G}. \quad (2.12)$$

Na etapa atual, $\mathbf{R}_B^L$ é assumida como identidade e $\mathbf{t}_B^L$ como nula até que a calibração extrínseca física seja medida. Essa hipótese simplifica o processamento inicial, mas deve ser substituída pelos parâmetros reais da montagem na validação final.

2.8 Filtragem estatística e física

Os sinais inerciais são suavizados por um filtro passa-baixa Butterworth de quarta ordem com frequência de corte de 5 Hz para acelerômetros e giroscópios. A filtragem reduz ruído de alta frequência antes da estimação de atitude, preservando a dinâmica relevante do ensaio [7].

Na nuvem LiDAR, os filtros são aplicados em sequência. Primeiro são removidos valores não numéricos, timestamps inconsistentes, ângulos fora de $[0, 36000]$, intensidades fora de $[0, 255]$ e distâncias abaixo do limite físico mínimo do sensor. Em seguida, o limiar de intensidade é calculado pelo método de Otsu, que escolhe o limiar τ que maximiza a variância entre classes:

$$\tau^* = \arg \max_{\tau} \left[w_0(\tau) w_1(\tau) (\mu_0(\tau) - \mu_1(\tau))^2 \right]. \quad (2.13)$$

O mesmo critério é aplicado à distância em escala $\log_{10}$ para separar leituras úteis de valores de alcance discrepantes. Por fim, saltos de pose são detectados por cerca externa de Tukey:

$$x > Q_3 + 3(Q_3 - Q_1), \quad (2.14)$$

aplicada às velocidades translacionais e angulares entre poses sucessivas [8, 18]. Essa combinação evita impor manualmente um único limite de velocidade e permite que a filtragem acompanhe a distribuição real do ensaio.

3

Metodologia

3.1 Visão geral

A metodologia foi organizada em duas etapas complementares. A primeira estima a posição e a atitude do drone a partir de fluxo óptico, ToF e IMU. A segunda usa a pose estimada para transformar os pontos do LiDAR principal para o referencial global.

O fluxo geral é:

1. aquisição embarcada de IMU, LiDAR, ToF e fluxo óptico;
2. conversão das leituras inerciais para unidades físicas;
3. calibração de viés do giroscópio e filtragem dos sinais;
4. estimação de atitude por Madgwick;
5. acumulação de deslocamento óptico no plano XY , corrigido por ToF;
6. preenchimento dos intervalos sem evento de fluxo óptico por propagação inercial;
7. associação da pose estimada a cada medição LiDAR;
8. filtragem e transformação dos pontos LiDAR para nuvem global.

3.2 Plataforma de aquisição

A plataforma de testes foi montada inicialmente em base móvel terrestre, permitindo validar aquisição, sincronismo e processamento com menor risco operacional antes da migração para voo. Os sensores foram fixados ao corpo da plataforma, de modo que as transformações entre LiDAR, IMU, sensor óptico e corpo do drone pudessem ser tratadas como transformações rígidas.

O sistema de aquisição embarcada integra os seguintes elementos:

Table 3.1: Componentes utilizados na aquisição embarcada

Componente	Interface	Função no sistema
Raspberry Pi Pico / RP2040	GPIO, I2C, SPI, UART	Coordenação da leitura dos sensores, timestamp e gravação em cartão SD
2x IMU da família MPU	I2C0 e I2C1	Aceleração e velocidade angular em três eixos
VL53L1X	I2C compartilhado com a IMU 1	Distância ToF usada para corrigir a escala do fluxo óptico
PMW3901	SPI1	Deslocamento incremental por fluxo óptico no plano observado
LD06	UART1 a 230400 baud	Distância, ângulo e intensidade dos pontos LiDAR
Cartão SD	SPI0	Registro contínuo dos dados em CSV

Há uma inconsistência nominal entre documentos do projeto: algumas anotações descrevem as IMUs como MPU-6050, enquanto a versão de aquisição mais recente menciona MPU6500. Como as escalas usadas correspondem às configurações $\pm 2g$ e $\pm 250^\circ/s$ comuns à família, o processamento permanece válido, mas o modelo físico exato deve ser confirmado na versão final da lista de materiais.

3.3 Dados coletados

O conjunto bruto de dados possui 19 colunas. Cada pacote LiDAR contém 12 pontos; para cada ponto salvo, o sistema embarcado registra o mesmo timestamp e as leituras mais recentes dos demais sensores. A estrutura é apresentada na Tabela 3.2.

Table 3.2: Variáveis registradas no CSV bruto

Variável	Fonte	Descrição
tempo_us	RP2040	Timestamp em microssegundos obtido por <code>micros()</code>
ax1, ay1, az1	IMU 1	Acelerações brutas nos três eixos
gx1, gy1, gz1	IMU 1	Velocidades angulares brutas nos três eixos
ax2, ay2, az2	IMU 2	Acelerações brutas nos três eixos
gx2, gy2, gz2	IMU 2	Velocidades angulares brutas nos três eixos
angle	LD06	Ângulo LiDAR em centésimos de grau
distance	LD06	Distância LiDAR em milímetros na base processada
intensity	LD06	Intensidade do retorno LiDAR, de 0 a 255
tof_mm	VL53L1X	Distância ToF em milímetros
flow_dx, flow_dy	PMW3901	Deslocamentos incrementais do sensor óptico, em centímetros após escala embarcada

A base processada contém 6.241 linhas, 521 timestamps distintos e duração aproximada de 52,07 s. Esses valores são usados apenas para caracterizar o ensaio. O ambiente de referência foi um corredor cujas dimensões horizontais foram medidas experimentalmente em três repetições para cada dimensão, buscando reduzir erros de medição manual. Os valores consolidados adotados foram largura de 1,20 m e comprimento de 7,00 m. A altura do teto não foi medida com precisão suficiente para ser usada como referência, de modo que a validação geométrica permanece limitada ao plano horizontal.

3.4 Pré-processamento da IMU

Timestamps duplicados são removidos para construir uma série temporal única de pose. Em seguida, calcula-se:

$$t_i = \frac{t_{us,i} - t_{us,0}}{10^6}, \quad \Delta t_i = t_i - t_{i-1}, \quad f_s \approx \frac{1}{\text{mediana}(\Delta t_i)}. \quad (3.1)$$

As acelerações e velocidades angulares são convertidas conforme a Equação 2.1. Amostras saturadas são marcadas quando qualquer eixo bruto atinge magnitude maior ou igual a 32600 LSB. Essa marcação é diagnóstica e não é usada para remover automaticamente linhas no processamento atual.

3.4.1 Calibração e filtragem

A janela inicial de $T_{calib} = 5$ s é assumida como repouso. Nela, o viés médio do giroscópio é estimado e subtraído:

$$\hat{\mathbf{b}}_\omega = \frac{1}{N_c} \sum_{i=1}^{N_c} \tilde{\omega}_i, \quad \omega_{corr,i} = \tilde{\omega}_i - \hat{\mathbf{b}}_\omega. \quad (3.2)$$

O acelerômetro não tem viés subtraído nessa versão do método, pois sua função principal é alimentar a estimativa de atitude e fornecer apoio curto nos intervalos sem medição óptica. Após a calibração do giroscópio, acelerômetros e giroscópios passam por filtro Butterworth passa-baixa de quarta ordem com frequência de corte de 5 Hz.

3.4.2 Média das duas IMUs

As duas IMUs são montadas no mesmo corpo rígido. Usa-se a média simples entre sensores:

$$\bar{\mathbf{a}} = \frac{\mathbf{a}_1 + \mathbf{a}_2}{2}, \quad \bar{\omega} = \frac{\omega_1 + \omega_2}{2}. \quad (3.3)$$

A média reduz ruído não correlacionado sem introduzir custo computacional significativo. Correções centrípetas e tangenciais entre IMUs foram desconsideradas nesta etapa porque o deslocamento físico entre sensores é pequeno em relação à resolução efetiva do deslocamento óptico.

3.5 Estimativa de atitude

A atitude inicial é estimada a partir da direção da gravidade observada no primeiro instante, com *yaw* inicial arbitrado como zero. O filtro de Madgwick propaga o quaternion usando o giroscópio corrigido e corrige a inclinação com o acelerômetro filtrado. Ao final, os quaternions são convertidos para ângulos de Euler na ordem xyz para exportação como:

$$\text{angle_x} = \phi, \quad \text{angle_y} = \theta, \quad \text{angle_z} = \psi. \quad (3.4)$$

Esses ângulos são usados para reconstruir $\mathbf{R}_B^G$ pela convenção $R_z(\psi)R_y(\theta)R_x(\phi)$.

3.6 Aceleração linear no mundo

Com a atitude estimada, a média das acelerações é transformada para o referencial global:

$$\mathbf{a}_{G,i} = \mathbf{R}_{B,i}^G \bar{\mathbf{a}}_{B,i} - \begin{bmatrix} 0 \\ 0 \\ g \end{bmatrix}. \quad (3.5)$$

No estudo atual, o componente vertical é mantido apenas como diagnóstico de remoção da gravidade. A posição vertical Z não é estimada, pois o sensor óptico disponível observa o plano horizontal e o ToF fornece apenas distância pontual ao solo, não odometria vertical.

3.7 Estimativa de posição por fluxo óptico e IMU

3.7.1 Fluxo óptico como fonte primária

O sensor óptico fornece deslocamentos incrementais `flow_dx` e `flow_dy`. O ToF é validado por faixa física:

$$h_i = \begin{cases} \text{tof_mm}_i, & 20 \leq \text{tof_mm}_i \leq 300, \\ h_0, & \text{caso contrário,} \end{cases} \quad h_0 = 90 \text{ mm.} \quad (3.6)$$

O deslocamento óptico corrigido é acumulado no plano XY conforme a Equação 2.3. Os eixos do sensor são mapeados diretamente para o referencial global conforme a orientação adotada na montagem; caso haja inversão física de eixos, os sinais devem ser ajustados na calibração.

3.7.2 Eventos de fluxo óptico e intervalos sem medição

Um evento de fluxo óptico ocorre quando:

$$\Delta x_{f,i} \neq 0 \quad \text{ou} \quad \Delta y_{f,i} \neq 0. \quad (3.7)$$

Sequências de zeros não são interpretadas automaticamente como repouso. Elas podem indicar movimento abaixo da resolução do sensor ou ausência temporária de medição. Por isso, entre eventos consecutivos, a aceleração linear nos eixos X e Y é integrada pela regra do trapézio, e o deslocamento inercial é ancorado aos pontos ópticos pelas extremidades do intervalo, como na Equação 2.10. Essa decisão mantém o fluxo óptico como referência de posição e limita o efeito da deriva inercial.

3.7.3 Associação da pose às medições LiDAR

A estimativa de pose é obtida em timestamps únicos, enquanto o conjunto bruto contém várias medições LiDAR para o mesmo timestamp. Para preservar todas as medições, associa-se a cada linha LiDAR a posição e a atitude do timestamp correspondente. Quando há linha bruta sem pose exata após deduplicação, usa-se a pose temporal mais próxima. O conjunto de dados usado na transformação da nuvem contém:

$$\{\text{tempo_us}, x, y, \text{angle_x}, \text{angle_y}, \text{angle_z}, \text{angle}, \text{distance}, \text{intensity}\}. \quad (3.8)$$

3.8 Processamento da nuvem LiDAR global

Na etapa de geração da nuvem, as unidades das medições LiDAR são configuradas explicitamente:

$$\theta_L[^\circ] = 0,01 \cdot \text{angle}, \quad r_L[\text{m}] = 0,001 \cdot \text{distance}. \quad (3.9)$$

Essa correção é importante porque versões antigas da documentação interna mencionavam distância em unidades de 0,25 mm, enquanto a documentação do LD06 e os dados processados nesta versão adotam milímetros.

3.8.1 Filtros aplicados à nuvem

Os filtros são aplicados na seguinte ordem:

1. valores numéricos finitos nas colunas obrigatórias;
2. timestamp positivo e não decrescente;
3. domínio do LiDAR: ângulo em $[0, 36000)$ e intensidade em $[0, 255]$;
4. distância mínima física de 0,02 m;
5. limiar de intensidade calculado por Otsu;

6. limiar superior de distância calculado por Otsu em $\log_{10}(r_L)$;
7. continuidade de pose por cerca externa de Tukey aplicada às velocidades translacional e angular.

A análise de bancada anterior indicou intensidade 223 como um limiar útil para rejeitar parte dos retornos fracos do LiDAR. Entretanto, no processamento final esse valor não é fixado: o limiar τ_I é determinado por Otsu a partir da distribuição real do ensaio, mantendo o valor de bancada apenas como referência histórica e como parâmetro de versões anteriores da aquisição.

3.8.2 Correção da rotação do LiDAR principal

A montagem adotada considera que o LiDAR principal gira em torno do eixo Y do drone. Portanto, a varredura local está no plano X - Z , e não no plano X - Y . A conversão local é a Equação 2.11. Nessa convenção, $\theta_L = 0$ aponta para $+Z$ do drone e o aumento de θ_L desloca o ponto em direção a $+X$. Caso o zero físico do sensor ou o sentido de rotação sejam diferentes, esses parâmetros devem ser ajustados na calibração geométrica.

3.8.3 Transformação para o referencial global

Após a conversão local, o ponto é transformado para o corpo do drone e, em seguida, para o mundo:

$$\mathbf{p}_B = \mathbf{R}_B^L \mathbf{p}_L + \mathbf{t}_B^L, \quad \mathbf{p}_G = \mathbf{R}_B^G \mathbf{p}_B + \mathbf{p}_{drone,G}. \quad (3.10)$$

Na etapa atual, adota-se $\mathbf{R}_B^L = \mathbf{I}$ e $\mathbf{t}_B^L = \mathbf{0}$ como hipótese inicial. Essa simplificação permite validar o fluxo de processamento, mas não substitui a calibração extrínseca final entre o centro de referência do drone e o centro óptico do LiDAR.

3.8.4 Análise de erro geométrico horizontal

Para avaliar preliminarmente a coerência geométrica da nuvem global, as dimensões horizontais medidas do corredor foram comparadas com as extensões estimadas na nuvem de pontos. A largura foi associada ao eixo X_{global} e o comprimento ao eixo Y_{global} , coerente com a trajetória predominante do ensaio. Como os extremos absolutos da nuvem podem ser afetados por retornos isolados, a estimativa dimensional adotou a amplitude robusta entre os percentis 5% e 95% de cada eixo horizontal.

Os erros são calculados por:

$$e_{abs} = |x_{estimado} - x_{real}|, \quad e_{rel}(\%) = \frac{|x_{estimado} - x_{real}|}{x_{real}} \cdot 100. \quad (3.11)$$

Essa comparação não utiliza a dimensão vertical devido à falta de medida precisa do teto. Também não constitui validação completa da localização absoluta, pois não emprega trajetória externa ponto a ponto para o drone. Assim, a referência experimental disponível deve ser entendida como parcial, concentrada nas dimensões horizontais conhecidas do corredor.

3.9 Produtos do processamento

O processamento gera dois produtos de dados: uma tabela de pose estimada associada a cada medição LiDAR e uma tabela final com as coordenadas locais, no corpo e globais dos pontos filtrados. No conjunto atualmente presente no projeto, a tabela de pose preserva as 6.241 linhas do CSV bruto. Após os filtros da nuvem, permanecem 1.041 pontos globais. Esses números descrevem o processamento dos arquivos disponíveis e não devem ser interpretados como medida definitiva de desempenho do sistema em outros cenários.

Implementação, Resultados e Conclusão

4.1 Implementação realizada

O sistema implementado integra aquisição embarcada, estimativa de pose e transformação de pontos LiDAR para um referencial global. A arquitetura segue a cadeia:

Fluxo óptico/ToF + IMU $\rightarrow$ pose do drone $\rightarrow$ transformação LiDAR $\rightarrow$ nuvem global

A Figura 4.1 resume a integração de hardware. O RP2040 coordena a leitura das duas IMUs, do ToF, do sensor óptico PMW3901 e do LiDAR LD06, registrando os dados em cartão SD. O LiDAR é usado como principal disparador de gravação: para cada pacote recebido, são salvos os pontos LiDAR e os valores mais recentes dos demais sensores.




Imagem 4.1: Arquitetura de hardware do sistema de aquisição, com microcontrolador, sensores inerciais, LiDAR, sensor óptico, ToF e armazenamento em cartão SD.

No processamento, a IMU deixou de ser tratada como fonte principal de posição por dupla integração livre. A versão atual utiliza o fluxo óptico como odometria primária em XY , corrigida pela distância ToF, e usa a IMU para estimar atitude e preencher intervalos sem evento de fluxo óptico. Essa alteração torna o método mais compatível com as limitações físicas dos sensores MEMS, nas quais ruído e viés tornam a integração inercial pura pouco confiável em intervalos longos.

4.2 Resultados obtidos

O conjunto bruto contém 6.241 linhas, 19 colunas e duração aproximada de 52,07 s. Após a deduplicação por timestamp na estimativa de pose, foram processados 521 instantes distintos. A tabela de pose preserva as 6.241 medições LiDAR originais, associando a cada linha uma posição x, y e uma atitude estimada.

A trajetória estimada permaneceu restrita ao plano horizontal. Na tabela de pose, x variou de 0 a aproximadamente 0,246 m, enquanto y variou de aproximadamente 0,020 a 7,191 m. Esses valores descrevem o ensaio processado e não representam, por si só, erro absoluto de localização. A referência experimental disponível é parcial: foram obtidas medidas reais de largura e comprimento do corredor, permitindo uma avaliação preliminar da coerência geométrica da nuvem no plano horizontal, embora não tenha sido empregada trajetória externa ponto a ponto.

Após a aplicação dos filtros físicos e estatísticos, a nuvem global resultante contém 1.041 pontos. A nuvem inclui as coordenadas locais do LiDAR, as coordenadas no corpo do drone e as coordenadas globais. As faixas globais observadas foram aproximadamente:

Table 4.1: Faixas de coordenadas da nuvem global exportada

Coordenada	Mínimo	Máximo
X_{global}	-3,298 m	2,703 m
Y_{global}	-0,596 m	7,709 m
Z_{global}	-2,769 m	3,261 m

As dimensões reais de referência do corredor foram obtidas por medição manual repetida três vezes para cada dimensão horizontal. A largura real adotada foi 1,20 m e o comprimento real adotado foi 7,00 m. A altura do teto não foi usada como referência quantitativa, pois essa dimensão não foi medida com precisão.

Para extrair as dimensões estimadas da nuvem, considerou-se a largura como a amplitude robusta do eixo X_{global} e o comprimento como a amplitude robusta do eixo Y_{global} . Foi usado o intervalo entre os percentis 5% e 95% para reduzir a influência de retornos isolados nas extremidades da nuvem. Com esse critério, a extensão horizontal estimada resultou nos erros apresentados na Tabela 4.2.

Table 4.2: Erro dimensional horizontal da nuvem global em relação às medidas reais do corredor

Dimensão	Valor real	Valor estimado	Erro absoluto	Erro relativo
Largura	1,20 m	1,951 m	0,751 m	62,61%
Comprimento	7,00 m	7,184 m	0,184 m	2,63%

O erro de comprimento foi baixo em relação à dimensão total do corredor, indicando coerência preliminar da escala longitudinal do processamento. A largura, por outro lado, apresentou erro relativo elevado. Esse resultado deve ser interpretado com cautela, pois a estimativa depende da dispersão transversal dos pontos, da calibração extrínseca ainda simplificada, da orientação física do LiDAR e da presença de retornos isolados. Assim, a comparação valida parcialmente a geometria horizontal da nuvem, mas não caracteriza validação completa da localização absoluta.

Essas coordenadas demonstram que o método transforma pontos LiDAR locais para uma nuvem tridimensional global, procedimento compatível com práticas de processamento de nuvens de pontos em robótica [10]. A qualidade geométrica final, entretanto, ainda depende de calibração extrínseca, validação do sentido físico do LiDAR e comparação com referências complementares do ambiente, além das dimensões horizontais já medidas.

Nuvem de pontos 3D no referencial global




Imagem 4.2: Representação tridimensional da nuvem de pontos global obtida a partir da transformação dos dados do LiDAR para o referencial global.




Imagem 4.3: Projeções ortogonais da nuvem de pontos global no plano horizontal, evidenciando a distribuição espacial dos pontos processados.

As Figuras 4.2 e 4.3 demonstram a geração da nuvem global a partir dos dados processados. A precisão geométrica dessa representação foi avaliada de forma preliminar pelas dimensões horizontais do corredor; uma validação mais completa ainda depende da calibração física dos sensores e de referências experimentais complementares, como a altura do teto e uma trajetória externa ponto a ponto.




Imagem 4.4: Resumo visual do processamento de navegação, incluindo ToF, odometria óptica, atitude, aceleração linear e trajetória final no plano XY.

4.3 Limitações

A principal limitação atual é a ausência de estimativa de posição vertical. O ToF mede distância pontual até a superfície observada e é usado apenas como correção de escala do fluxo óptico. Sem um segundo sensor óptico orientado para observar um plano vertical, ou sem outro método de altitude, a posição Z do drone é assumida como 0 m no processamento da nuvem. Além disso, como a altura do teto não foi medida com precisão suficiente, a validação dimensional vertical do ambiente permanece limitada.

Outra limitação é a calibração extrínseca. Nesta etapa, usa-se $\mathbf{R}_B^L = \mathbf{I}$ e $\mathbf{t}_B^L = \mathbf{0}$ como valores iniciais. Essa hipótese é útil para validar o fluxo de processamento, mas a reconstrução final precisa medir a translação e a rotação reais entre o LiDAR, o corpo do drone e o ponto de referência da pose.

Também há limitações na atitude. O filtro de Madgwick combina giroscópios e acelerômetros, mas não utiliza magnetômetro ou referência externa de rumo. Assim, o yaw inicial é arbitrário e pode acumular deriva ao longo do tempo. Essa deriva afeta diretamente a rotação da nuvem global.

4.4 Conclusão

O trabalho consolidou uma abordagem de localização relativa e mapeamento tridimensional para ambientes não assistidos por GPS, utilizando sensores de baixo custo. A análise técnica do método desenvolvido indica que, para o ensaio experimental considerado, a fusão entre fluxo óptico, sensor ToF e IMU apresenta maior adequação do que a utilização isolada da integração inercial. Isso ocorre porque o sensor óptico fornece uma estimativa direta do deslocamento relativo no plano XY , enquanto a IMU contribui para a estimativa de atitude e para a propagação do estado em intervalos curtos nos quais haja perda ou indisponibilidade temporária das medições ópticas.

A partir da pose estimada do sistema, os pontos obtidos pelo LiDAR podem ser filtrados, convertidos inicialmente para coordenadas locais no plano $X-Z$ e, posteriormente, transformados para o referencial global. Dessa forma, torna-se possível reconstruir uma nuvem de pontos global coerente com a trajetória estimada do veículo, permitindo a representação tridimensional do ambiente analisado.

Os resultados obtidos demonstram a viabilidade do fluxo de processamento proposto e a possibilidade de geração de uma nuvem de pontos global a partir dos dados disponíveis. Com as medidas reais de largura e comprimento do corredor, tornou-se possível realizar uma avaliação preliminar do erro geométrico horizontal da nuvem. O comprimento estimado apresentou erro absoluto de 0,184 m, equivalente a 2,63%, enquanto a largura estimada apresentou erro absoluto de 0,751 m, equivalente a 62,61%. Esses valores indicam coerência parcial da escala longitudinal, mas também evidenciam limitações relevantes na estimativa transversal.

Entretanto, o sistema ainda não deve ser caracterizado como uma solução de localização absoluta plenamente validada. A etapa atual comprova a integração funcional dos sensores e a consistência matemática do método empregado, enquanto a avaliação quantitativa completa da precisão depende de calibração física final, melhor controle experimental e comparação com referências complementares às dimensões horizontais já disponíveis. A falta de medida precisa do teto limita a validação da dimensão vertical.

Para aplicações em drones aquáticos ou subaquáticos, recomenda-se avaliar a substituição do sensor óptico por sensores de pressão distribuídos nos três eixos, em uma configuração análoga ao princípio de funcionamento de um tubo de Pitot, de modo a estimar velocidades relativas ao fluido. Já para drones aéreos, recomenda-se a utilização de sensores ópticos adicionais, especialmente para melhorar a estimativa de altitude. Alternativamente, a inclusão de múltiplos sensores ópticos pode fornecer redundância nos diferentes eixos de medição, aumentando a robustez do sistema de localização relativa.

4.5 Trabalhos futuros

Os próximos passos recomendados são:

- adicionar uma fonte de estimativa vertical ou um segundo sensor óptico para odometria em Z ;
- avaliar filtros probabilísticos de fusão, como Kalman estendido ou fatoração em grafo, quando houver modelo de incerteza calibrado;
- migrar a validação da plataforma terrestre para o drone aéreo após estabilizar aquisição, peso, alimentação e fixação mecânica dos sensores;
- integrar Inteligência artificial e/ou algoritmos de controle para navegação autônoma, utilizando os dados de LiDAR com integração com módulo de rádio para o controle do drone.

Bibliografia

- [1] Randal W. Beard and Timothy W. McLain. *Small Unmanned Aircraft: Theory and Practice*. Princeton University Press, 2012. ISBN: 9780691149219.
- [2] James Diebel. *Representing Attitude: Euler Angles, Unit Quaternions, and Rotation Vectors*. Technical report. Stanford University, 2006.
- [3] Jay A. Farrell. *Aided Navigation: GPS with High Rate Sensors*. McGraw-Hill, 2008. ISBN: 9780071493291.
- [4] Paul D. Groves. *Principles of GNSS, Inertial, and Multisensor Integrated Navigation Systems*. 2nd ed. Artech House, 2013. ISBN: 9781608070053.
- [5] Bruce D. Lucas and Takeo Kanade. “An Iterative Image Registration Technique with an Application to Stereo Vision”. In: *Proceedings of the 7th International Joint Conference on Artificial Intelligence*. 1981, pp. 674–679.
- [6] Sebastian O. H. Madgwick. *An Efficient Orientation Filter for Inertial and Inertial/Magnetic Sensor Arrays*. Technical report. x-io and University of Bristol, 2010. URL: https://x-io.co.uk/res/doc/madgwick_internal_report.pdf (visited on 06/09/2026).
- [7] Alan V. Oppenheim, Ronald W. Schaffer, and John R. Buck. *Discrete-Time Signal Processing*. 2nd ed. Prentice Hall, 1999. ISBN: 9780137549207.
- [8] Nobuyuki Otsu. “A Threshold Selection Method from Gray-Level Histograms”. In: *IEEE Transactions on Systems, Man, and Cybernetics* 9.1 (1979), pp. 62–66. DOI: [10.1109/TSMC.1979.4310076](https://doi.org/10.1109/TSMC.1979.4310076).
- [9] PixArt Imaging Inc. *PMW3901MB-TXQT: Optical Motion Tracking Chip Product Datasheet*. Version 1.00, 20 Mar. 2017. 2017. URL: <https://www.digikey.com/htmldatasheets/production/2456773/0/0/1/pmw3901mb.pdf> (visited on 06/09/2026).
- [10] Radu Bogdan Rusu and Steve Cousins. “3D Is Here: Point Cloud Library (PCL)”. In: *2011 IEEE International Conference on Robotics and Automation*. 2011, pp. 1–4. DOI: [10.1109/ICRA.2011.5980567](https://doi.org/10.1109/ICRA.2011.5980567). URL: https://pointclouds.org/assets/pdf/pcl_icra2011.pdf (visited on 06/09/2026).
- [11] Shenzhen LDROBOT Co., Ltd. *LD06 Data Sheet: Super Mini DTOF Principle Lidar*. 2019. URL: https://www.yahboom.net/xiazai/LiDar-LD06/LDROBOT_LD06_Datasheet.pdf (visited on 06/09/2026).
- [12] Bruno Siciliano et al. *Robotics: Modelling, Planning and Control*. Springer, 2009. ISBN: 9781846286414. DOI: [10.1007/978-1-84628-642-1](https://doi.org/10.1007/978-1-84628-642-1).
- [13] STMicroelectronics. *VL53L1X: A New Generation, Long Distance Ranging Time-of-Flight Sensor Based on ST’s FlightSense Technology*. Datasheet DS12385, Rev. 8, Aug. 2024. 2024. URL: <https://www.st.com/content/ccc/resource/technical/document/datasheet/group3/7d/85/c8/95/fb/3b/4e/2d/DM00452094/files/DM00452094.pdf/jcr:content/translations/en.DM00452094.pdf> (visited on 06/09/2026).
- [14] TDK InvenSense. *MPU-6000 and MPU-6050 Register Map and Descriptions*. Revision 4.2, 19 Aug. 2013. 2013.
- [15] TDK InvenSense. *MPU-6500 Product Specification*. Document PS-MPU-6500A-01. 2013. URL: <https://invensense.tdk.com/wp-content/uploads/2020/06/PS-MPU-6500A-01-v1.3.pdf> (visited on 06/09/2026).
- [16] Sebastian Thrun, Wolfram Burgard, and Dieter Fox. *Probabilistic Robotics*. MIT Press, 2005. ISBN: 9780262201629.

- [17] David H. Titterton and John L. Weston. *Strapdown Inertial Navigation Technology*. 2nd ed. American Institute of Aeronautics and Astronautics, 2004. ISBN: 9781563476938.
- [18] John W. Tukey. *Exploratory Data Analysis*. Addison-Wesley, 1977.